


Proyecto - Etapa 1

Curso Web Semántica MISIS

Rubén Manrique & Nicolás Klopstock


Objetivo del Proyecto

El proyecto tiene como objetivo aplicar los conceptos y tecnologías de la Web Semántica para la extracción, integración, modelamiento y vinculación de información proveniente de fuentes de datos heterogéneas en el dominio musical. Como producto final, los estudiantes construirán un grafo de conocimiento que integre información sobre canciones, artistas y otros conceptos del dominio. Este, posteriormente, será enriquecido mediante fuentes de Linked Data y utilizado en conjunto con modelos de lenguaje de gran escala (LLM) para la recuperación y generación de información.



El proyecto se desarrollará en tres etapas. En la primera etapa, los estudiantes deberán extraer información desde distintas fuentes de datos relacionadas con el dominio musical. A partir de la información obtenida, identificarán las principales clases del dominio, sus miembros, los atributos que las describen, las relaciones entre ellas y las relaciones jerárquicas existentes. El resultado de esta etapa será un modelo conceptual preliminar que servirá como base para el desarrollo de la ontología.

En la segunda etapa, los estudiantes formalizarán el modelo conceptual mediante una ontología, utilizando tecnologías de la Web Semántica y un modelo de lenguaje de gran escala (LLM) como apoyo



al proceso de diseño y validación. Posteriormente, deberán poblar la ontología con la información extraída durante la primera etapa, almacenar el conocimiento resultante en una base de datos orientada a grafos y realizar consultas sobre dicho grafo utilizando los lenguajes y herramientas correspondientes.

Finalmente, en la tercera etapa, los estudiantes deberán vincular su ontología y su grafo de conocimiento con otras ontologías y fuentes de Linked Data. A partir de esta integración, utilizarán el conocimiento disponible en conjunto con un modelo de lenguaje para desarrollar una aplicación o mecanismo de consulta y recuperación de información basado en grafos, siguiendo un enfoque como GraphRAG o uno similar.

ETAPA 1


Cada grupo recibirá un dataset inicial compuesto por aproximadamente **100.000 canciones** obtenidas a partir de Million Song Dataset. Para cada canción se proporcionará únicamente un conjunto básico de datos, que incluye información como el título de la canción, artista, álbum, año, duración y algunos identificadores disponibles.

El objetivo principal de esta etapa es enriquecer este dataset inicial. A partir de las 100.000 canciones suministradas, cada grupo deberá buscar, extraer e integrar automáticamente la mayor cantidad posible de información adicional utilizando fuentes de datos externas. El resultado de esta etapa deberá conservar las canciones del conjunto inicial e incorporar nuevas características y relaciones encontradas para ellas y para las entidades asociadas. La información adicional puede incluir, entre otras, **características acústicas** de las grabaciones (por ejemplo: tempo, tonalidad, escala, sonoridad o características rítmicas); **información descriptiva de la canción y sus grabaciones**; y datos relacionados con **artistas, álbumes, compositores, escritores, productores, sellos discográficos, géneros, colaboraciones, premios** u otras entidades y relaciones que los grupos identifiquen como relevantes dentro del dominio musical.

Para realizar este enriquecimiento deberán identificar y utilizar fuentes que permitan complementar los registros suministrados. Podrán utilizar APIs, datasets públicos, servicios Web u otras fuentes que permitan realizar la extracción de información de manera automatizada. La integración deberá realizarse estableciendo correspondencias entre los registros del dataset inicial y las entidades encontradas en las fuentes externas. **No se considerará enriquecimiento la simple incorporación de conjuntos de datos que no hayan sido vinculados con las canciones suministradas.**

MusicBrainz y AcousticBrainz constituyen dos posibles fuentes para realizar este proceso. MusicBrainz permite obtener y relacionar información sobre artistas, grabaciones, obras, lanzamientos y otras entidades del dominio musical. Por su parte, AcousticBrainz contiene descriptores acústicos previamente calculados para diferentes grabaciones musicales. Los estudiantes no deberán realizar análisis de las señales de audio ni calcular características musicales directamente.

El uso de estas fuentes NO es obligatorio. Los grupos podrán utilizar otras fuentes de información siempre y cuando documenten su procedencia y justifiquen su utilidad.



Consideraciones

- No se requiere realizar análisis de audio ni calcular características acústicas de las canciones. Cuando se utilicen este tipo de características, deberán provenir de fuentes o datasets existentes.
- Para la extracción y enriquecimiento de información pueden utilizar, entre otras, las siguientes fuentes:
 - MusicBrainz (https://musicbrainz.org/doc/MusicBrainz_Database/Schema)
 - AcousticBrainz (<https://acousticbrainz.org/data>)

Los grupos podrán identificar y utilizar fuentes adicionales que permitan enriquecer el conjunto de datos.

- La información obtenida deberá poder relacionarse con los registros del dataset inicial. No es suficiente descargar conjuntos de datos independientes sin establecer correspondencias entre sus entidades.
- El proceso de extracción e integración deberá ser reproducible mediante el código entregado. Se espera que cada grupo resulte con más de 75.000 instancias de canciones.

Entregables

- Documento de máximo 4 páginas que describa las fuentes utilizadas, la información disponible en cada una, el proceso de extracción, reconciliación, integración y limpieza de los datos, las tecnologías utilizadas y los principales retos y problemas encontrados.
- El modelo conceptual preliminar, indicando las clases, relaciones y jerarquías identificadas. Puede ser en un diagrama o en texto en un documento anexo.
- Código fuente correspondiente al proceso de extracción, reconciliación, integración y limpieza desarrollado. El código deberá permitir reproducir el proceso realizado a partir del dataset inicial. Se puede entregar el repositorio de GitHub (por favor, asegurarse de dejar el repositorio **Público**).
- Dataset consolidado con la información obtenida y enriquecida durante la etapa. Para cada registro deberá ser posible identificar la fuente o fuentes de las cuales se obtuvo la información y los identificadores utilizados para establecer correspondencias entre ellas. Entregable en uno o varios archivos .csv.